Архитектура кластера хранения данных

В целом система была задумана как кластер для безопасного хранения конфиденциальных и не очень конфиденциальных данных достаточно разнородных интернет-ресурсов и мобильных приложений с быстрым доступом. Некоторые части архитектуры, которые я специально выделю ниже, могут быть весьма странными и неоднозначными, однако, я вас уверяю, это требования заказчика, отказаться от которых отказался.

Схема 1. Общее представление архитектуры кластера

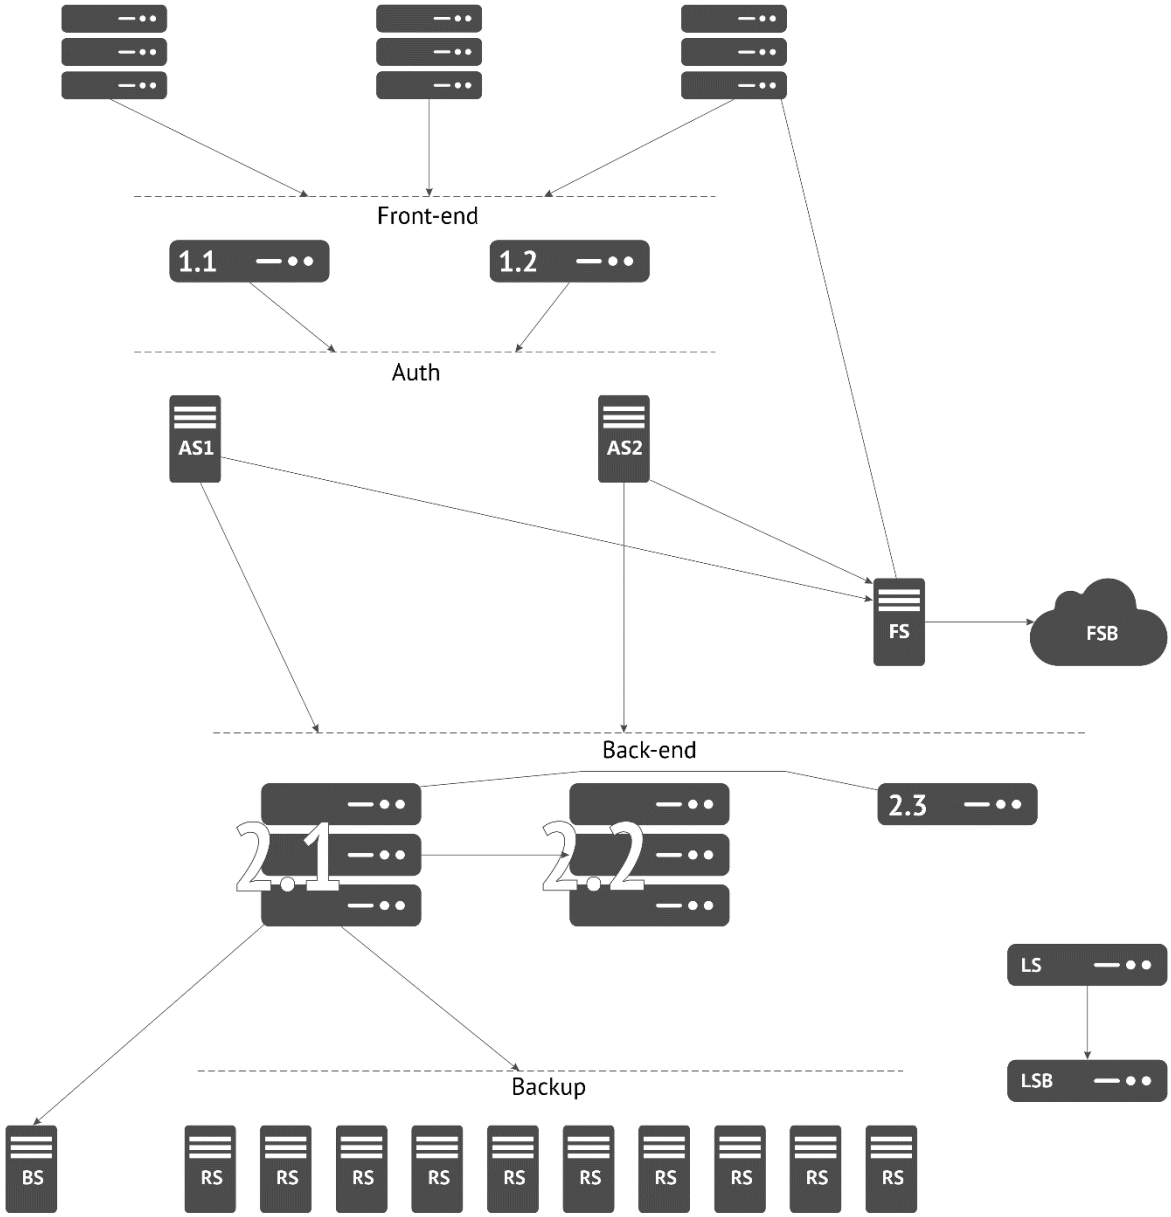

Суть

Зоопарк вышеописанных проектов (сайты, мобильные приложения) будет обращаться в нашему хранилищу для записи и чтения разообразных данных.

Текстовая информация должна преимущественно храниться в базах данных PostgreSQL. Однако, для некоторых видов информации предусмотрены колоночные и key-value хранилища, но задачи для подобных альтенативных решений пока определены не точно, поэтому на первом этапе разработки они не будут внесены в архитектуру.

Файлы будут храниться в файловом хранилище представляющим собой обычный каталог с подкаталогами, в которых будут храниться файлы и который будет бэкапиться в хранилище Google Drive. Существует так же алетернативный подход к хранению, заключающийся в написание собственного софта аналогичного Haystack, но решение о таком развитии архитектуры будет принято уже после старта первой версии системы. О хранении файлов будет отдельная часть позже.

Большая часть запросов, приходящих на вход кластера будет представлять собой HTTP-пакеты, на борту которых будет закодированное сообщение о том что же мы все-таки хотим сделать с данными, чаще всего запрос или несколько запросов к базам данных. Эти сообщения будут попадать на уровень front-end (сервера 1.1 и 1.2 на схеме, далее FES).

Кроме того, будут HTTP-запросы типа POST или PUT, которые будут нести с собой файл для записи в файловое хранилище, а так же метаданные, о которых подробнее будет рассказано в разделе о хранении файлов. В этом случае, если запись файла будет разрешена он попадет в хранилище, а затем будет среплицирован в резервное хранилище в облаке Google.

Но не HTTP единым...

Как же WebSocket и прочие UDP?

У нас их не будет. Пока не будет. Пока в них нет неоходимости, широкого применения им не найти, а частные случаи использования лучше решать проектам-клиентам «на местах».

Серверами исполняющими запросы являются узлы уровня back-end, в основном это машины 2.1 и 2.2; машина 2.3 так же учавствует в исполнении запросов, на ней исполняются только запросы с особо важными, такими как платежи и перводы денежных средств, изменение основных данных пользователей и т. п. Таким образом 2.3 есть вспомогательный сервер для обеспечения большей надежности и безопасности храниения критичных данных.

Собственно, большая часть работы кластера будет крутиться вокруг исполнения запросов к базам данных, лежащих на серверах уровня back-end. Ноды 2.1 и 2.2 связаны как master-slave сервера и в лучшем случае дублируют друг друга. Предполагается что 2.1 и 2.2 будут работать совместно: запросы на чтение будут выполняться на обоих серверах, а запросы на изменение данных – только на 2.1.

Далее предполагается что полезные данные будут «растекаться» по машинам уровня backup, которые могут распределены географически. Необходимо разделить все

хранилище баз данных на логические части, условием объединения баз в 1 логическую часть может быть отношение к одному и тому же проекту, либо, напротив, использование БД несколькими проектами одновременно. Решение может выглядеть весьма странным: зачем плодить столько отдельных бэкап-серверов, но причина выбора такой конфигурации этого уровня выбрано заказчиком, скорее, из полических соображений, нежели из объективной неоходимости – каждый проект, использующий нашу систему хранения хочет хранить копию своих данных у себя на серверах (если таковые имеются).

Не обойдется, безусловно, и без бэкап-сервера, объедияющего в себе всю храняющуюся полезную информацию (узел BS).

Кроме того, в систему будет включена пара серверов хранения логов (машины LS и LSB). По названиям, думаю, должно быть понятно, что главный здесь сервер LS, а LSB является бэкапом для LS. Наличие LSB нельзя назвать обязательным, однако в случае его отсутствия желательно иметь RAID-массив на LS, например, RAID 10, ибо потеря логов хоть и не критична, но может быть весьма неприятна.

Отдельно стоит остановиться на сервере авторизации (AS) и, собственно, системе авторизации и прав на исполнение запросов. Требования к безопасности данных привели к тому, что каждое действие над данными должно быть авторизовано, проверено на соответствие прав доступа и задокументировано. Алгоритм проверки следующий:

Сообщение с запросом приходит на FES.

От FES делается запрос к серверу AS с целью узнать доступно ли конкретное действие с конкретными данными для ресурса/пользователя, от имени котрого прислано сообщение.

В случае если от AS разрешает выполнение запрос или запросы передаются слою back-end или файловому серверу, в противном случае система возвращает ответ о невозможности выполнения запроса/запросов.

В случае попытки записать файл, сначала на вход FES приходит сообщение с запросом разрешения записи файла, в случае положительного ответа от AS, клиенту возвращается кодированная последовательность (на манер идентификатора сессии). На борту с этой последовательностью и с файлом для записи клиент затем стучится в файловое хранилище и если последовательность является легитимной, то файл будет сохранен в хранилище.

Теперь рассмотрим каждую часть системы подробнее...

Передовая. Front-end

Уровень front-end содержит 2 сервера, которые превращают пришедшее на вход сообщение в запрос или запросы, а так же держат очередь этих преобразованных

сообщений. Строго говоря, можно и не использовать 2 сервера сразу, а держать второй сервер только для failover'a в случае падения или компрометации основной ноды. Но поскольку сервера 2, то почему бы не использовать сразу и второй раз он все равно включен… Думаю имеет смысл сделать их полностью одинаковыми, получающими запросы по алгоритму Round-robin DNS, то есть поочередно: на уровне DNS каждый следующий запрос прокидывается то на первый, то на второй сервер.

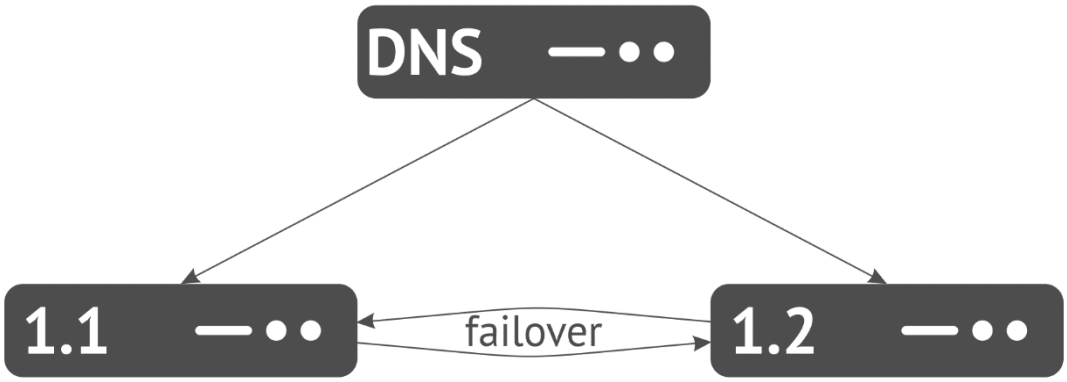

Описание функционала:

1. **Превращение сообщений в запросы**

Изначально, сообщения были задуманы как способ скрыть конкретику запроса данных, а так же сократить тело запроса. Фактически сообщение это бинарная последовательность, которая может быть использована 2 способами:

Либо мы кодируем в сообщение текст и параметры запроса некой обратимой хэш-функцией;

Либо отпраляем лишь идентификатор запроса и его параметры, так же в кодированном виде, а по прибытии на FES ищем соответствие идентификатора запроса с конкретным запросом в таблице возможных сообщений.

Первый способ можно использовать при условии что тексты запросов будут недлинными, либо хэширующая функция будет достаточно минифицировать тексты.

Преимущество первого способа может проявиться при наличии очень большого числа возможных сообщений, кое неминуемо образуется после более-менее серьезного срока эксплуатации системы.

Однако, даже при количестве запросов в миллион их беспрепятственно можно хранить в любом персистентном key-value хранилище, на ум, в первую очередь, приходит Redis, что даст нам скорость доступа практически не зависящую от количества элементов в хранилище. Таким образом второй способ выглядит предпочтительнее.

Тем не менее, при неблагоприятных условиях хранения, скажем, если все данные о миллионе запросов, по каким-то причинам, не будут влазить в память, использование этого способа может стать неоправданным.

В целом, я склоняюсь к использованию втрого метода, так как его проблемы выглядят проще решаемыми, относительно проблем первого метода.

2. **Очередь сообщений**

Речь о том, что AS может не успевать проксировать или отклонять все поступающие к нему запросы. Логично продублировать AS и тем самым решить эту проблему. Собственно, от этого варианта никто и не отказывается, но априори хочется не обременять заказчика дополнительными тратами на втророй сервер авторизации, а обойтись тем что есть. А на случай возникновения задержек при проксировании, сообщения будут складываться в очередь, предположительно организованную при помощи Redis.

Думаю имеет смысл создать пул постоянных соединений с AS и без устали совать в них новые сообщения из очереди.

И 1 и 2 пункты мы собираемся решать при помощи самописного ПО.

3. **Heartbeat**

Механизм HeartBeat позволяет анализировать работоспособность узлов в системе и автоматически изменять конфигурацию кластера, либо производить определенные действия в ответ на потерю одной или нескольких нод. В данном случае в механизме учавствуют сервера 1.1 и 1.2.

Для этого можно использовать одноименный пакет.

Heartbeat обеспечивает основные функции, требующиеся для любой HA-системы, например, запуск и останов ресурсов, мониторинг доступности системы в кластере и передача прав владения общим IP-адресом между узлами кластера. Он следит за состоянием конкретной службы (или служб) по последовательному кабелю, интерфейсу Ethernet, либо по обоим. Поддерживает двухузловую конфигурацию, в которой для проверки состояния и доступности службы используется специальный квитирующий монитор heartbeat. Heartbeat предоставляет фундамент для более сложных сценариев.

Вроде через него можно даже load balancing делать можно, но эту функциональность использовать не будем.

Нам нужно следующее:

1) каждый из узлов уровня front-end должен как можно быстрее что его «товарищ» в беде и не может отвечать на запросы;
2) как только узлу это становится ясно он должен попробовать реанимировать товарища (перезапустить сервисы, наример), а если это не удалось – сообщить админу (про это подробнее ниже).

О проверке прав...

Заказчик хочет сделать сервер авторизации отдельным, и по приходу каждого сообщения запрашивать права на исполнения соответствующих команд. Гораздо быстрее работало бы решение с размещением небольшого хранилища данных о правах пользователей на выполнение запросов в front-end серверах без запросов к удаленному серверу. С другой стороны, есть мнение что такое решение небезопасно. Надо разобраться в этом вопросе.

Сделаем допущение что сервер авторизации на 100% недоступен извне кластера (в случае выделенного AS). Тогда единственный способ добраться до него (исключая физической соединение с сервером) это получить рут-доступ к FES и уже с него стучаться на сервер авторизации. Предотвратить исполнение каких бы то ни было команд, посланных злоумышленником с FES мы может следующими способами:

- обрубить связь между скомпрометированным сервером и AS при возникновении подозрений у системы обнаружения вторжений (СОВ). Вот оказывается как, нужна еще и система обнаружения вторжений. Какая-то СОВ обязательно будет установлена, но ее отладка и настройка до оптимального регирования процедура не мгновенная, да и гантировать впоследствие ее безошибочное срабатывание нельзя;
- поключаясь к хранилищу мы проходим авторизацию под определенным пользователем. Так давайте дадим этому условному пользователю только те права, которые ему жизнено неоходимы. В таком случае условный хакер пробравшийся на front-end машину не сможет разрушить сервер авторизации, а так же не сможет получить большую часть данных и инициировать их стирание и т. п. В таком случае, что изменения иных, защищенных параметром сервера и хранилища придется подключаться к серверу напрямую, что может быть неудобно, но зато безопасно.

В случае если хранилище данных авторизации лежит локально, то безусловно это решение может быть быстрее и надежнее при определенных условиях. Однако, условия эти вовсе необязательно должны иметь место. Если FES и AS находятся на одном физическом сервере в виде виртуальных серверов, однако оверхэд будет небольшим и не всегда очевидным: в случае хранения авторизационных данных на FES подключаться к хранилищу можно посредством Unix-сокета, при связи же VDS – VDS подключение может быть только с использованием сетевого (TCP) сокета что чуть медленее и менее надежно + оверхэд на взаимодействие между виртуальными

машинами. Если же сервера размещены на рызных машинах, то встает вопрос как они соединены – если по Fibre Channel или другому быстрому интерфейсу и машины находятся недалеко друг от друга (одна стойка, одна серверная, один ДЦ) то больших потерь от этого ждать не стоит.

Однако, как не крути, когда все внутри одной ОС взаимодействие будет быстрее, хоть эту разницу и можно свести к минимуму...

А вот потери в безопасности в этом случае могут быть совсем не маленькими, поскольку появление злоумышленника на машине с auth-данными, с рут-правами соответствующего хранилища или, что еще хуже, появления его в рут-правами системными может потенциально привести к компрометации и уничтожению всей системы.

Поэтому мы остановимся, все же, на конфиграции с отдельным сервером авторизации, как бы я тяготел к произвотельным системам, беопасность, в данном случае, важнее.

Давайте остановимся на безопасности и производительности front-end серверов и всей системы в целом, так как оные являются единственной точкой входа в кластер из окружающего мира.

И так, у FES'ов открыты порт для подключений от серверов (его номер не принципиален, но предположим что это 80-й) и порт для подключения по SSH (по умолчанию он 22-й, но лучше сменим на другой, например, на 22022).

80-й порт открыт только для определнных IP, на которых висят проекты использующие наш кластер, таким образом чтобы получить доступ к FES нужно залезть на один из «разрешенных» серверов или прикинуться одним из таких серверов, а затем организовать от имени этого сервера атаку на 80-й. Допустим на нем висит nginx и у нас есть оболденный xploit, который умеет эксплуатировать некую уязвимость, переполнять буфер и выполнять произвольный код под рутом. Ситуация ужасная, но давайте попробуем сократить ее ужасность.

Выжечь все подконтрольной машине можно, но кроме прекращения работы кластера это ничего не даст. Чтобы получить доступ к данным проектов нужно попасть на сервера уровня back-end, чтобы накуралесить на сервере авторизации на него, так же, нужно еще попасть. AS, как уже было выше сказано, открыт только на подключения с FES под опреденным пользователем, который ничего почти не может. Так что даже если удалось найти данные для подключения само это подключение ничего собственно не даст.

У меня есть идея сделать сервер авторизации шлюзом между front-end и back-end серверами. То есть, раскодированное сообщение попадая на AS проверяется на разрешенность и в случае положительного вердикта пробрасывается на уровень back-end, иначе возвращает FES сообщение о невозможности выполнения.

Таким образом чтобы получить какие-либо секретные данные, либо устроить их потерю с FES злоумышленнику надо долго и упорно бомбардировать CA комбинациями команд и параметром дабы угадать комбинацию и быть пропущеным системой и все это во враждебной инфраструктуре с COB, рискую быть «спаленым».

Все в основном крутится вокруг AS и его как можно более широкого канала на входе.

Канал действительно широкий и стабильный дабы переварить трафик с уровня front-end без больших сетевых задержек.

Вот так плавно мы перешли к детальному рассмотрению сервера авторизации.

Про этот компонент системы уже довольно много было написано. Пара серверов AS по реализации во многом похожа на front-end сервера: 2 дублирующих сервера с failover'ом друг на друга и DNS-rount-robin балансировкой.

Хранилище авторизационных данных должно как можно более быстрым и поддерживать репликацию master-master. Структурирование данных в данном случае особо ни к чему, посему я в данном случае смотрю в стороны NoSQL-решений. Запрос авторизационных данных в хранилище скорее всего будет подрузумевать попытку найти запись в БД, удовлетворяющую опредeнным критериям (запрашивающий пользователь, проект, устройство и т. п.), так что напрашиваются колоночные СУБД, но критериев все-такие не предполагается много, так что такое решение тоже выглядит избыточным. Думаю, использование key-value СУБД будет вполне оправданным, учитывая скорость выборки данных из таких систем. Redis как решение выглядит препочтительным учитывая его распространенность и простоту, но Redis не поддерживает синхронную репликацию, по крайней мере пока. В качестве алетернативы есть, например, Riak, у которого вышеоговоренная репликация имеется, но Riak система не в пример сложнее и функциональнее Redis, и немного медленнее, а нам усложнение как бы ни к чему и скорость в приоритете. А master-master можно реализовать и на уровне bash-скриптов, например, или на Lua, как как аддон для Redis. На нем и остановимся пока.

Помимо описанного выше осталось только основное предназначение CA: На машине так же должна быть установлена COB следящая за неизменяемостью этого компонента сервера.

Функциональность.

1. Авторизация запросов данных

Обращаемся к вышеописанному хранилищу при помощи, например, bash-скрипта или простого приложения и получаем простой ответ: «да» или «нет» (1 или 0, true или false, неважно). Далее пробрасываем транзакцию на back-end. Просто же…

2. **Балансировка нагрузки серверов уровня back-end**

Вариант 1. pgPool-II.

pgPool умеет балансировать select'ы способом Round-robin, таким образом мы всю запись производим на мастер, а выборки раскидываем между мастером и слэйвом. Репликация, посредством Streaming Replication.

Вариант 2. pgPool-II (with Replication).

В этом варианте будет использоваться синхронная репликация pgPool вместо потоковой репликации. В остальном подход не отличается от предыдущего. Master-master репликация может дать ощутимый проигрыш в производительности на запись, однако, мы будем получать при балансировке посредством pgPool всегда актуальные данные из пары backend-серверов. Отмечу, что если не настроить корректно кэш в pgPool, то будут тормозить и select'ы.

Изначально, планируется использовать сервер 2.1 как основной и 2.2 как вспогательный. Механика работы следующая: при условии полной работоспособности сервера 2.1 (ответы от него возвращаются в установленное максимальное время ответа или менее) все запросы – и на запись и на чтение поступают на этот сервер, все изменения данных реплицируются при помощи потоковой репликации на сервер 2.2, запросы на этот сервер начинают поступать только в случае, если основной сервер не справляется с нагрузкой и это могут быть только запросы на чтение – запросы на запись всегда должны идти на главный back-end сервер. В случае если основной сервер падает, основным и единственным отдувающимся становится 2.2, по крайней мере до подъема 2.1.

Логика выбора такой методологии проста: при небольшой нагрузке на кластер предотвратить возвращение неактуальных данных и упростить процедуру репликации в противовес альтернативному подходу...

Который представляет собой либо стандартную Round-robin балансировку на чтение между 2.1 и 2.2 в случае если сервера примерно одинаковы по производительности, либо Weighted Round Robin, если 2.1 разнятся по скорости обработки запросов, либо балансировку Least Connections, что выглядит предпочтительным способом балансировки относительно предыдущих, особенно в случае неоднородной нагрузки. Однако, самым идеальным вариантом можно назвать балансировку со сбором статистики о каждом back-end сервере. Имеется ввиду, что балансировщик мониторит нагрузку, используемые ресурсы, время отклика каждого сервера и т. п., и исходя из этой информации принимает решение какому из сервером отдать на исполнение следующий запрос на выборку.

Вариант 3. HAProxy.

Позволю себе выдержку из Википедии…

*«**HAProxy** — серверное программное обеспечение для обеспечения высокой доступности и балансировки нагрузки для TCP и HTTP-приложений, посредством распределения входящих запросов на несколько обслуживающих серверов…»*

Утверждается что:

1U сервера оснащённые Xeon E5 (2014 года) и 10 Гбит/с сетевой картой без проблем обрабатывают поток 40—60 Гбит/с, при этом подчёркивается, что ограничивающим фактором является пропускная способность сетевой карты.[10]

Даже на процессоре Intel Atom 1,6 ГГц (без воздушного охлаждения) HAProxy удалось обрабатывать поток до 1 ГБит/с.[10]

Расход памяти: 1 Гб ОЗУ хватает для обслуживания ~20 000—30 000 одновременных сессий.

HAProxy умеет балансировать нагрузку на PostgreSQL и Redis (думаю, при использовании других СУБД он и с ними справится), переключать мастер при падении и снимать статистику о состоянии того или иного back-end сервера. Инструмент отличный по функционалу и использованию ресурсов. Единственное что смущает это его редкое использование совместно с PostgreSQL – могут вылезти грабли.

Вариант 5. nginx.

Nginx без проблем проксирует запросы к PostgreSQL, Memcahed, Redis и другим СУБД при подключении соответствующих модулей. Кроме того, nginx умеет распределять нагрузку, однако собрать статистику с проксируемых сервером и определить их нагруженность, в полном смысле этих выражений, без дополнительных скриптов не удастся, зато можно использовать следующие варианты балансировки:

round-robin (по умолчанию) – в объянениях, я думаю, не нуждается – стандартный Round-robin алгоритм с поочередным задействованием всех отвечающих серверов в пуле;

weighted round-robin – Round-robin с весами – на выбор очередности выбора сервера влияет вес узла: узлы с большим весом обрабатываются чаще;

hash - метод балансировки нагрузки для группы нод, при котором соответствие клиента серверу определяется при помощи хэшированного значения *ключа*. В качестве *ключа* может использоваться текст, переменные и их комбинации;

ip_hash - метод балансировки нагрузки, при котором запросы распределяются по серверам на основе IP-адресов клиентов. В качестве ключа для хэширования используются первые три октета IPv4-адреса клиента или IPv6-адрес клиента целиком. Метод гарантирует, что запросы одного и того же клиента будут всегда передаваться на один и тот же сервер;

least_conn - метод балансировки нагрузки, при котором запрос передаётся серверу с наименьшим числом активных соединений, с учётом весов серверов. Если подходит сразу несколько серверов, они выбираются циклически (в режиме round-robin) с учётом их весов;

least_time - метод балансировки нагрузки, при котором запрос передаётся серверу с наименьшими средним временем ответа и числом активных соединений с учётом весов серверов. Если подходит сразу несколько серверов, то они выбираются циклически (в режиме round-robin) с учётом их весов.

Методы least_time и least_conn с натяжкой можно назвать методами с мониторингом балансируемых серверов, хоть и очень простым.

Кроме того nginx может переключить мастер при его крахе.

На этом можно, пожалуй, можно закончить рассморение этого компонента кластера, ибо я и так многовато рассказал :-)

Давайте теперь поговорим о файловом хранилище.

У меня было стойкое нежелание прогонять файлы через front-end сервер и через сервер авторизации, так что я придумал принимать решение о загрузке файла в хранилище до отправки самого файла. К тому же не плохо было бы не загружать файлы и на сервера проектов. Таким образозом нам надо сделать авторизованую загрузку из браузера в кластер на сервер/сервера файлов.

Предположим мы хотим загрузить новую видеолекцию на наш образовательный ресурс. Из веб-интрефейса проекта мы делаем запрос к серверу проекта, мол нам бы записать файл «Лекция по квантовой механике», в формате mp4, размером 240 Мб, с датой последнего изменения 24 января 2016 г. в 20:21 и хэш-суммой F6DE2FEA. Затем сервер проекта добавляет к запросу идентификатор пользователя, которым инициирована загрузка и пр. мета-инфу и отправляет запрос кластеру хранения. Запрос попадает на AS и в случае «законности» операции отвечает «Загрузку разрешаю», делает он это отправляя уникалый идентификатор загрузки, а параллельно скидывает сообщение файловому серверу «В течение 10 секунд к тебе начнет

поступать файл «Лекция по квантовой механике», в формате mp4, размером 240 Мб, с датой последнего изменения 24 января 2016 г. в 20:21 и хэш-суммой F6DE2FEA». Сервер файлов сохраняет информацию о новом файле в очереди файлов и пишет инофрмацию о ново файле в хранилище мета-информации. Сервер проекта получив положительный ответ сообщает его в браузер, где скрипт должен в ответ на это начать загрузку файла. Большие файлы должны быть поделены на части и могут отправляться следующими способами:

- последовательная отправка частей файла;
- параллельно, в любое доступное количество потоков.

Небольшие же файлы отправляются сразу одной частью. Решение о том, что считать большим файлом, а что маленьким принимает клиент – вместе с мета-информацией о файле он отправляет пометку что хотел бы отправлять файл по частям или что хотел бы отправить все одним куском. Преимущество «частичной» загрузки еще и в том, что при ее использовании можно организовать докачку файлов и индикацию прогресса загрузки: пока файл не полностью закачен или с последнего сеанса загрузки не прошло слишком много времени ФС ожидает докачку всех частей файла, а прогресс изменяется с каждой новой закаченной частью.

Чтобы файловый сервер знал к какому конкретно файлу имеют отношение приходящие параллельно куски каждый кусок несет с собой идентификатор загрузки, описанный выше, как бы говоря ФС: «Я кусок номер 3 от файла 176». Загрузка заканчивается, когда достигнут заявленый размер файла, после этого файл собирается из кусков в единое целое. Если итоговый размер файла больше заявленного – лишнее обрезается, а приславшему отправляется соответствующее сообщение.

Если какой-либо кусок приходит второй раз он замещает предыдущий.

После полного получения файла, запись о нем удаляется из очереди файлов, а все необходимые данные пишутся уже в персистентное хранилище.

Каждый записанный файл проверяется на соответствие заявленной хэш-сумме: демон в фоне расчитывает хэш каждого нового файла и сравнивает ее с сохраненной суммой, заявленной для этого файла (той что приходила в запросе на закачку). Если хэши не совпали файл удаляется, а в базу данных о файлах пишется соответствующая пометка.

Стоит отметить что природа операции по записи в ФС транзакционна. То есть, при неудачной записи файла (по любым причинам) данные об этом файле с БД будут откатаны, а вот при неудачной записи мета-данных в базу сервер опробует еще пару раз это сделать и только потом запретит загрузку файла.

Если касаться аппаратной части, то желательно использование твердотельных накопителей в аппаратном RAID 10 с батарейкой, ибо сеть, согласно статистике, уже обогнала обычные HDD, а писать нам нам надо как раз из сети и желательно без задержек. Но на самом деле это не так принципиально – даже если вместо SSD будут серверные HDD нас выручит RAID даже при немалых нагрузках. Судите сами, какой

должен быть входящий поток, чтобы повесить систему, если у нас есть 8 дисков в RAID 10 с кэшем на 1Гб :-) Получается мы пишем и читаем одновременно в 4 потока: по 1 потоку на пару дисков-зеркал, сразу на оба диска. Если приравнять скорость сети к скорости серверного HDD (и это еще очень грубое допущение, так как это передача по внутренней сети, а то и через WWW, на самом деле скорость закачки будет много меньше скорости диска, по крайней мере в России). То получается мы может писать и читать параллельно 4 файла совсем без задержек. А ведь есть еще гигабайтный кэш. На вскидку не скажу на каком количестве параллельно записывающихся файлов будет ощущаться «заторможенность», но думаю это число не меньше 50, особенно на суд нашего, неизболованного скоростью закачки, российского пользователя. Большие и редкозапрашиваемые файлы можно не пускать в кэш дабы не забивать его

Нужно ли такой машине много оперативной памяти? Скорее да, чем нет. Положим, гигабайт 8 можно выделить под частоиспользуемые небольшие файлы и на этом хорош.

Для еще большей производительности на запись желательно писать файлы последовательно, тогда не будет тратиться время на перемещение головки диска. В этом случае нам бы помог Haystack, но как по мне, для использования таких решений они должны быть действительно необходимы.

Haystack - проект Массачусетского технологического институт, используется в Facebook для хранения тонны картинок, генерируемых огромной армией пользователей социальной сети. Не вдаваясь в подробности стоит сказать что основное ноу-хау этой системы – возможность последовательно писать и читать с HDD.

Очень крутая вещь, но открытой реализации нет с общем доступе. Есть только идеи которые можно раелизовать своими силами, что пока видится излишней тратой сил, так как пока не понятно будет ли подсистема хранения файлов работать под такой нагрузкой, чтобы решения типа Haystack давали реальный прирост в производительности. Короче говоря, пока нужды в такой разработке нет.

Синхронизация ФС с резервной копией в Google Drive, в идеальном случае, должна происходить во времена относительной незагруженности канала ФС. Более-менее это время можно спрогнозировать по статистике, но вегда есть вероятность что синхронизация случится, все же, в далеко не в лучшее время и повлияет на загрузку новых файлов на ФС. Думаю, лушим способом будет выделить, к примеру, 20% канала на синхронизацию и размазать нагрузку на все время. Таким образом основная задача по закачке новых файлов с клиентов хоть и потеряет 20% пропускной способности, но

зато этот канал будет всегда стандартизирован, как и канал синхронизации и они гарантировано не будет «воровать» друг у друга ресурсы. Приведенной мной соотношение 80/20 можно варьировать в зависимости от ситуации с производительностью – не будет ли одна из задач излишне запаздывать относительно другой. Изменение соотношения можно изменять и автоматически, если снимать соответствующие сетевые показатели, скажем, раз в 5 минут и в засимости от них менять баланс.

Кроме того, некоторые файлы, потеря которых некритична, можно вовсе не бэкапить. Тогда канал на выгрузку в облачное хранилище будет экономиться.

А как обстоят дела с чтением файлов?

Почти так же как и с чтением текстовых данных: шлем сообщение с клиента о том что хотим получить файл, если нам это разрешено, то получаем редирект на местнахождение этого файла на ФС.

А откуда этот редирект?

Сервер авторизации при соответствии прав на файл спрашивает ссылку на него у файлового сервера.

Если же файл потерялся, был удален и т. п., то ФС возвратит ошибку, которую СА бережно передаст клиенту. Может статься так что на ФС файл был утерян (не удален, это большая разница), а на бэкапе он в наличии. Сгенерировать ссылку на бэкап не получится, так как Google Drive не даст получить закрытые от внешнего мира файлы без авторизации, а авторизованным для резервного хранилища у нас является только основной ФС. Все файлы в гугль-хранилище, сохраненные от имени ФС являются именно закрытыми, думаю, понятно почему. В таком случае мы должны ответить что файл временно недоступен и немедленно запустить восстановление его из бэкапа. За самим файлом мы можем сходить в Google Drive, а вот чтобы восстановать данные БД нам так же нужен и бэкап БД. Где разместить этот бэкап? Отдельный сервер городить под эту задачу не хочется. Для начала будет оставлять бэкапы все на том же ФС и дополнительно складывать в ФСБ.

Что делать если файл побился?

В случае такой нехорошей ситуации, мы ее должны, в первую очередь, идентифицировать: предполагается запуск дополнительного демона, который в фоне будет пересчитывать хэш-суммы файлов и сравнивать их с сохраненными в базе данных. По очереди, отсортированной по сроку без проверки и обновлений, то есть сначала те, которые давно не проверялись и не обновлялись. Возможно использование и других алгоритмов, например, основанных на размере файла (чем меньше файл, тем быстрее считается его хэш, так может сначала проверять маленькие файлы?), частоте запрашивания и изменения файла, а так же алгоритмических гибридов. Важно понимать что такой демон не решит всех проблем, он только снизит вероятность

нахождения на сервере битого файла, кроме того он будет отъедать ресурсы и его бесконтрольное использование может сократить производительность основных компонентов. Так что тут нужны тесты, на основе которых нужно найти количество выделяемых ресурсов, при котором работа демона не будет бить по работоспособности других систем.

Удаление файлов. Эта операция должна быть атомарна в пределах файлового хранилища:

Удаляем файл.

Удаляем запись в БД или помечаем неактивной.

Отправляем сигнал FSB удалить файл из бэкапа.

Операции 1.1 и 1.2 можно выполнять параллельно. При возникновении в любой из операций все уже совершенные откатываются.

Но как это сделать? В смысле как откатить удаление уже удаленного файла? В Linux, например, есть такое решение https://github.com/sindresorhus/trash-cli - реализация корзины с утравлением из командной строки. Так же всем известны пляски с алиасом на rm – не красивое, но рабочее решение.

Самое интересное. Back-end сервера.

Запросы к этому уровню попадают от AS, в случае если он разрешает получение или изменение данных.

На каждом сервере необходимо поднять пул соеденений к базам данных. Строго говоря, его использование не смотря на, вроде бы, очевидную пользу не всегда позитивно влияет на производетельность доступа к данным в плане повторного использования соединений. Вроде бы, это же хорошо когда не нужно на каждую транзакцию создавать новое соединение с БД: выделять память, авторизовываться и т. д., но все же доплнительный слой взаимодействия в виде пула пожет вносить оверхэд, а его преимущества могут практически повторяться использованием постоянных соеденений клиентов напрямую к БД. В нашем случае, у нас только один узел поключается к базам данных – AS, если он будет pconnect со всеми базами, возможно, это будет быстрее, чем использование пула соединений, в будущем нам ждут тесты на этот счет, но по тестам с увеличением нагрузки прирост производительности от задействования пула становится весьма ощутимым. Что ж, проверим…В любом случае выбрать и установить его нужно.

Оптимальным вариантом для реализации выглядит pgBouncer. Он не требователен к ресурсам и не несет с собой практически никакого оверхэда, но в случае активного использования pgPool-II для других целей (о чем позже) имеет смысл отказаться от pgBouncer как раз в пользу данного функционала pgPool-II, дабы не создавать лишний слой абстракции, а с ним и точку отказа и возможного увеличения latency.

Оба решения имеют функционал для организации очереди запросов: если в какой-то момент все соединения из пула заняты, пришедший на вход запрос может быть добавлен в очередь и будет ждать свободного соединения.

И так, запрос попадает на условный порт X на котором живет pgBouncer, в случае наличия свободных соединений к БД в пуле мы забираем одно из них, иначе ждем освобождения соединения в очереди. По большому счету это все что делает сервер. Его задачи – делать свою работу быстро и бессбойно. Машине (желательно физической), при возрастающей нагрузке, будет необходимо все больше памяти для соответствия строгих требований по производельности. Диски логично выбрать типа HDD, так как они пока еще остаются более надежными нежели твердотельные. А вот на скорости вращения лучше не экономить 15 000 об./мин. самое то. Так же нам понадобится аппаратный RAID 10 с батарейкой и достаточным кэшем, при его наличии можно принебречь кэшем дисков.

Пара BES будет объединена как master-slave, с потоковой репликацией.

На счет актуальности даных со slave. По правде говоря, мы всегда можем получить со слейва неактуальные данные, если репликация еще не прошла и в нем лежит предыдущая версия данных. К сожалению, это «необходимое зло» чтобы добиться хорошей проиводительности кластера. Но все же некоторые данные очень хотелось бы получать исключительно актуальными. Этого можно добиться балансируя запросы к BES'ам на AS с учетом этого требования. Как этого добиться вопрос скорее практический нежели теоретический. Основная задача это как-то отделись эти критические запросы от всех остальных так-то чтобы это разделение заметил балансировщик и отправил нужные запросы на мастер. При помощи nginx это не выглядит неподъемной задачей. Реализация будет позже.

При падении мастера долен происходить failover на slave. Потери некритичных данных при этом вполне возможны. А вот самые важные данные либо будут продулированы на 2.3, либо кластер отчитается в ответе об ошибке записи.

Если подробнее. То потери возможны на данных, которые неуспели отреплицироваться на slave. При падении масттера они будут утеряны. В время неработоспособности мастера все запросы будут на новоиспеченный мастер, бывший слейв. Соответствующие измения должны произойти в конфигурации балансировщика нагрузки, точнее балансировку следует на время прекратить и слать все запросы по одному адресу. После подъема «настоящего» мастера можно пойти двумя путями:

- оставить все как есть. То есть сделать прежний мастер слейвом. И работать как так и надо. В этом случае сервера 2.1 и 2.2 должны быть идентичными, что может быть экономически невыгодно;
- реализовать логику обратного перехода. В таком случае 2.1 и 2.2 должны поработать в режиме синхронной репликации. Как только 2.1 догонит 2.2 «догонит» 2.2 можно перейти на старую схему с 2.1 в роли мастера. И включить снова балансировку на AS.

Отдельно стоит рассказаться о сервере 2.3.

Некоторые особа важные запросы, касающиеся измения, например, финасовой информации, учетных данных пользователей и т. п. будут дублироваться на сервере 2.3 в режиме синхронной репликации. Как вариант, можно использовать логическую репликацию определенных таблиц, хранящих важные данные. Проще говоря, после записи данных в мастер (например, сервер 2.1) они должны быть записаны на сервер 2.3 и пока они туда железно не записались мастер не может ответить что данные записаны. Этот сервер должен быть прежде всего надежным. Значит мне хотелось бы видеть на нем аппаратный RAID, например, 61 с батарейкой. Хранилища, будь это PostgreSQL и что-то другое, должны быть настроены на максимальную надежность, это значит запись, по возможности, сразу на диск – упреждающая запись.

Собственно все. Простота есть одна из причин, благодарю которым мы можем добиться от сервером того что нужно: хорошей производительности, надежности и безопасности.

Кстати о безопасности. Сервера 2.3 работает только с одним открым портом для репликации от 2.1 (мастера). 2.2 ждет подключений с 2.1 на репликацию и с AS для выполнения запров на чтение. Для пущего спокойствия можно пользователю БД на 2.2, через которого подключается AS дать права только на чтение. Мастер, в свою очередь, может принимать запросы от AS и на чтение и на изменение.

Вот так.

Поговорим о серверах хранения логов.

Я считаю что логи со всех основных машин лучше хранить в одном месте что даст возможность ими удобно управлять и анализировать.

Систем сборки логов сечас великое множество. Например, Scribe или Fluentd.

Работа большей части из них сводится к демону, работающему на сервере приложения и следящему за измениями в файлах логов приложений. Как только измения появляются они отправляются на машину-хранилище логов. Многие системы еще и анализируют логи и предоставляют обработанную информацию в графическом виде, что может быть очень удобным.

Никаких «велосипедов» здесь не планируется. Берем готовое, желательно, бесплатное решение и используем его. Будет здорово, если будет возможность допилить кое-какие аспекты под себя.

Трафик на машину с логами будет бешеный как и нагрузка на диски. Возникает вопрос о целесообразности такое решения. Нам нужна будет машина с быстрыми дисками в RAID'e + ее связь со всеми машинами кластера. Поскольку частичная потеря логов не критична, то можно воспользоваться трердотельными накопителями. К тому же у нас будет еще и сервер бэкапа логов. На нем мы можем использовать, например, RAID 60 из старых-добрых HDD, если даже запись будет запаздывать - не беда. А вот на

основном сервере логов (LS) лучше юзать RAID 50 для удобоваримой скорости и неплохой надежности. Реплицировать логи с LS на LSB я собираюсь при помощи обычного rsync.

Бесполезная нагрузка. Бэкап уровень.

Была бы моя воля, я бы, конечно, оставил этот уровень. Вот только в нем был бы всего 1 сервер. Но имеем то что имеем.

По задумке, на каждом сервере концентрируются данных исходя из их отношения к определенному проекту или огранизации (как точно пока не определились) + некоторые данные, как то данные пользователей, стоят особняком, так как к ним обращаются все проекты, для них тоже нужен отдельный RS.

Кстати, у кого-то возникнет вопрос почему машины уровня backup называются RS? Ведь по логике предыдущих сокращений они должны зваться BS. Но нет. В терминах заказчика эти сервера зовутся «сервера ресурсов» (resource servers), так что RS.

Так вот. На машинах уровня back-end все данных, хранящиеся в PostgreSQL (а таких большинство) лежат в одной базе, для более простых и быстрых join'ов без FDW, логически поделенной на схемы по такому же принципу как поделены данные между серверами ресурсов. Таким образом, нам нужно реплицировать (именно реплицировать, а не бэкапить, ибо данные на RS должны быть живыми – лежащими в базе данных, готовыми к использованию) каждую схему на отдельный RS. Средствами стандартной и всеми любимой потоковой репликации тут никак не справиться, так как она не дает возможности реплицироваться отдельные схемы базы. Нужна логическая репликация.

Можно сказать хорошей логической репликации в PostgreSQL нет. В 9.5 появилась логиская репликация из коробки - Logical Decoding, но назвать ее полноценной язык не поворачивается, пока это сыроватое решение, хоть и с перспективой.

Вот, например:

Logical Decoding требует записи дополнительной информации в WAL. Не критично, но неприятно;

никакой параллельности, каскадная репликация не поддерживается.

Покрутим-попробуем, может подойдет. Тем более 9.5 уже вышла, так сказать, больше стабильности по едее…

Есть так же сторонние уже потертые решения а-ля Slony, Bucardo, Londiste, pgPool-II, которые по слухам не блещат производительностью или многообещающая разработка BDR, которую собираются запилить в postgres в одной из следующих версий. В случае некошерности Logical Decoding будем пробовать прикрутить pgPool-II, процесс этот обещает быть не сложным и в будущем не приносить хлопот: на pgPool много

документации, статей, примеров его производительность и стабильность не хуже аналогов, к тому же мы можем для пула соединений, очереди и репликации на RSы использовать только одно приложение – pgPool-II, а pgBouncer выкинуть. Скорость репликации нам в данном случае не принципиальна, хотя, безусловно, чем быстрее тем лучше. Но, само собой, скоростей потоковой репликации нам не достичь. Ну и ладно. Вряд ли «отставание» данных на RSax будет для кого-то критичным.

Над аппаратной начинкой сервером ресурсов нам, видимо, корпеть не придется, все на совести «хранителей» конкретного RS, пусть исходят из своих задач, а мы если что подскажем.

Чуть не забы про сервер BS. В нужности которого я сомневаюсь. По идее там будет храниться бэкап базы с 2.1. Вроде бы зачем он нужен если у нас и так 2 дублирующих сервера на back-end уровне (а для некоторых данных все 3). Но есть вероятность, что побитые данные с 2.1 перетекут потоком на другие сервера уровня и все станет не хорошо. Все споконее иметь бэкап. Можно сохранять его на BS, например, раз в сутки и хранить бэкапы за последнюю неделю. Разумеется все ахивированное. Широта души в этом случае зависит от размера баз данных.

Отступлние: про СУБД отличные от PostgreSQL.

Зоопарк СУБД пока не утвержден. Известно лишь что будут Postgres и Redis. Есть задача для которой хорошо подойдет колоночная система на манер Vertica или InfoBright. И неизвестно что еще придет в голову добавить в качестве хранилищ данных. Хорошо отношусь к MongoDB и Tarantool, но задач под эти решения пока нет, что может и хорошо.

Все вышеупомянутые СУБД умеют растекаться на кластер, бэкапиться, быстро и надежно работать, имеют армию приверженцев и хороший багаж проектов с их участием. Так что не пропадем! :-)